



Projeto Text Similarity

António Augusto Fernandes Simões Pereira

Nº 21136 – Regime Pós-laboral

Orientação

Prof. Joaquim Gonçalves

Prof. Patrícia Leite

Ano letivo 2022/2023

Licenciatura em Engenharia de Sistemas Informáticos

Escola Superior de Tecnologia

Instituto Politécnico do Cávado e do Ave

Identificação do Aluno

António Augusto Fernandes Simões Pereira

Aluno número 21136, regime pós-laboral

Licenciatura em Engenharia de Sistemas Informáticos

Orientação

Prof. Joaquim Gonçalves

Prof. Patrícia Leite

ÍNDICE

1.	Introdução	VII
1.1.	Objetivos.....	1
1.2.	Contexto	1
1.3.	Estrutura do documento	1
2.	Estado da arte.....	3
2.1.	Re-LSTM: A long short-term memory network text similarity algorithm based on weighted word embedding. (Weidong Z., 2022)	3
2.2.	A Short Text Similarity Calculation Method Combining Semantic and Headword Attention Mechanism (Mingyu J., 2022)	4
2.3.	Computing semantic similarity of texts based on deep graph learning with ability to use semantic role label information. (Majid M., 2022)	5
2.4.	A fast text similarity measure for large document collections using multireference cosine and genetic algorithm. (Mohammadi, 2020)	6
3.	Tecnologias utilizadas.....	7
3.1.	Sklearn	7
3.2.	Python	7
3.3.	Flask.....	7
3.4.	MongoDB.....	7
3.5.	Kotlin.....	8
4.	Trabalho Desenvolvido	9
4.1.	Backend.....	9
4.2.	Mobile App.....	12
4.3.	Testes e Resultados.....	13
4.3.1.	Primeiro teste	13
4.3.1.1.	Categoria - Facility Related	13
4.3.1.2.	Categoria - Product Related.....	14
4.3.1.3.	Categoria - Other	15

4.3.2.	Segundo Teste.....	15
4.3.2.1.	Categoria – Facility Related.....	15
4.3.2.2.	Categoria – Product Related.....	16
4.3.2.3.	Categoria - Other	16
4.4.	Conclusão	17
5.	Bibliografia	XVIII

Siglas e Acrónimos

NLP – Natural Language Processing (Processamento de linguagem natural)

DDS – Drug-Drug Similarity

LSTM – Long Short-Term Memory

HA-RCNN - Hierarchical Attentive Recurrent Convolutional Neural Network

DGNN – Directed Graph Neural Network

SRL - Semantic Role Labelling

TF-IDF - Term Frequency-Inverse Document Frequency

1. Introdução

O processamento de linguagem natural (Natural Language Processing) é uma das áreas da inteligência artificial que visa a interpretação e produção de linguagem natural (fala e escrita humana), por parte de computadores. Uma das funções do processamento de linguagem natural é a similaridade de texto que envolve medir o grau de semelhança entre dois textos. A similaridade de texto é extremamente importante para aplicações como verificação de plágio ou identificação de documentos duplicados, mas também pode ser aplicado a programas de reclamações ou de informações de medicamentos.

Neste projeto serão exploradas as bases da similaridade de texto e as suas principais técnicas e ferramentas utilizadas. Serão estudados diferentes algoritmos de processamento de linguagem natural e como estes podem ser utilizados para medir a similaridade entre textos de variados temas e explicação das abordagens para a avaliação desses algoritmos.

1.1. Objetivos

Os principais objetivos são a criação de uma aplicação capaz de reconhecer palavras-chave através de métodos que estão introduzidos na área da similaridade de texto e, por fim, apresentar a informação recolhida num dispositivo móvel.

1.2. Contexto

Este projeto final de licenciatura orientado pelo professor Joaquim Gonçalves e pela professora Patrícia Leite tem como principal objetivo a assimilação dos vários conceitos da área da similaridade de texto e pretende construir.

1.3. Estrutura do documento

Em relação à estrutura do documento estes são os principais tópicos;

1. Análise do estado da arte (Artigos relacionados);
2. Implementação, em que se descrevam as tecnologias escolhidas (e se justifiquem), e se refira detalhes sobre a implementação.
3. Análise de resultados e testes, seja uma análise/avaliação aos resultados obtidos, sejam testes de usabilidade ou unitários ao trabalho desenvolvido.
4. Conclusão

2. Estado da arte

Com a crescente procura de aplicações que utilizem a similaridade de texto nos diversos setores, o investimento na pesquisa da mesma é extremamente importante para que novas tecnologias, que são necessárias no nosso quotidiano, sejam desenvolvidas e aprimoradas.

No contexto de text similarity são utilizados diferentes modelos de redes neurais, que são nada mais nada menos que redes artificiais inspiradas no cérebro humano e têm vários usos como o reconhecimento de padrões e o processamento de linguagem natural. Estas redes neurais possuem diversos mecanismos de atenção que permitem ao modelo focar-se em partes específicas dos dados de entrada atribuindo pesos diferentes a palavras diferentes do texto dado.

2.1. Re-LSTM: A long short-term memory network text similarity algorithm based on weighted word embedding. (Weidong Z., 2022)

Os autores deste artigo utilizaram o algoritmo Re-LSTM (Long Short-Term Memory) como o seu modelo de computação de similaridade de texto, que utiliza uma rede neural recorrente (LSTM) para extrair características implícitas no texto. Este modelo utiliza uma abordagem de incorporação palavras ponderada através do algoritmo χ^2 -C que avalia as diferentes palavras encontradas no texto através da sua categoria e frequência com que aparece no documento.

Outro método utilizado neste modelo é o TF-IDF (Term Frequency-Inverse Document Frequency) que é uma técnica utilizada no processamento de linguagem natural para medir a importância relativa de uma palavra presente em um ou vários documentos. Isto é possível calculando o peso de cada palavra com base na quantidade de vezes que aparece num documento específico ou vários documentos do mesmo tema. Se uma palavra aparece várias vezes num documento vai ter um peso maior pois é mais importante nesse documento específico.

2.2.A Short Text Similarity Calculation Method Combining Semantic and Headword Attention Mechanism (Mingyu J., 2022)

Segundo os autores, este modelo teve um comportamento muito bom em relação a outros modelos com mecanismos de atenção, ainda que a dimensão da amostra utilizada no *dataset*¹ seja reduzida. o que os leva a acreditar que com uma amostra maior os resultados poderiam ser melhores também (ATEC utilizado para detetar fraudes discais e MSRP com o preço de carros indicado pelo fabricante e usado para tentar determinar o seu preço no futuro).

O modelo de rede neural usado é o Hierarchical Attentive Recurrent Convolutional Neural Network (HA-RCNN) que consiste na hierarquização das palavras em árvore através do seu “mecanismo de atenção” que se concentra nas partes importantes de um texto.

¹ Um conjunto de dados para treino do modelo

2.3. Computing semantic similarity of texts based on deep graph learning with ability to use semantic role label information. (Majid M., 2022)

O modelo de rede neural utilizado pelos autores neste projeto é o Directed Graph Neural Network (DGNN) que trabalha com grafos de relação semântica (Semantic Role Labelling – SRL) para calcular a similaridade semântica do texto (Text Similarity).

Neste caso os autores fizeram dois testes um com SRL + DG (um grafo direcional convencional) e outro com SRL + SDG (um grafo em que todos os tipos de arestas são considerados como um único tipo). Os resultados observados permitiram aos autores concluir que o segundo tipo de grafo aumenta o desempenho do algoritmo em relação a um grafo convencional devido.

2.4.A fast text similarity measure for large document collections using multireference cosine and genetic algorithm. (Mohammadi, 2020)

Os autores deste artigo falam-nos sobre a importância da utilização da similaridade de texto para o aumento do desempenho dos motores de busca como por exemplo o Google.

Para que o desempenho de um motor de busca aumente é preciso remover todas as pesquisas com artigos/textos que sejam iguais ou similares para que diminua o número de resultados presentes no *index* resultando num tempo de pesquisa menor e menor probabilidade de encontrar informação repetida.

Os métodos utilizados neste tipo de texto similarity são chamados de Duplicate or Near-Duplicate – DND que, tal como o nome indica, são utilizados para encontrar artigos/textos idênticos para que não seja apresentada informação duplicada. Neste projeto foi utilizado o cosine texto similarity algorithm que cria, através da análise de várias partes de um artigo, um vetor term frequency-inverse document frequency (TF-IDF). Através deste vetor é possível saber se um outro texto que for analisado é igual ou parecido se o ângulo dos vetores for parecido.

3. Tecnologias utilizadas

A escolha das tecnologias utilizadas é crucial para atingir os objetivos estabelecidos no projeto, pois cada uma destas tecnologias desempenha um papel fundamental na construção e operação do mesmo.

3.1. Sklearn

É uma biblioteca python que tem à disposição vários algoritmos de machine learning, como é o caso do método de Naive Bayes e é conhecida pela sua facilidade de uso.

É necessária a utilização da biblioteca Sklearn para que seja calculado o grau de similaridade das várias frases dadas utilizando o modelo treinado e, assim, seja atribuída a cada frase a sua respetiva categoria.

3.2. Python

A linguagem de programação escolhida foi o Python devido à maior disponibilidade de documentação sobre o tema do projeto que trata a similaridade de texto (NLP) em relação a outras linguagens de programação.

3.3. Flask

Para que a aplicação backend em python que trata do cálculo da similaridade de texto consiga comunicar e enviar informação para o frontend foi necessário escolher uma api capaz de atender as necessidades do projeto e, por isso foi escolhida a biblioteca Flask por ser eficiente, simples e fácil de integrar no projeto.

3.4. MongoDB

A base de dados escolhida para este trabalho foi a mongodb visto que a informação que estamos a guardar tem apenas dois atributos, a frase da reclamação a ser analisada e a respetiva categoria atribuída pelo modelo. A exportação da informação é feita através de um ficheiro json o que facilita a sua utilização na aplicação móvel.

3.5. Kotlin

Para a criação da aplicação móvel foi utilizada a linguagem Kotlin uma vez que é a linguagem que foi abordada na cadeira de Programação de Dispositivos Móveis e, por isso, utilizei os conhecimentos adquiridos na mesma para produzir uma aplicação móvel que permite a visualização da informação dada pela aplicação original.

4. Trabalho Desenvolvido

4.1. Backend

Em relação ao backend foi feito um modelo de treino que poderia conter várias categorias e era treinado dando uma frase e a sua respetiva categoria. Depois do modelo estar treinado é analisada cada frase de um ficheiro de texto externo e atribuída a respetiva categoria para cada uma das frases.

```
categories = [  
    "facility_related",  
    "product_related",  
    "other",  
]
```

No excerto de código acima estão representadas as possíveis categorias que podem ser atribuídas às frases.

```
training_complaints = [  
    "The stairs are too steep and dangerous.",  
    "The restroom is not clean and needs maintenance.",  
    "The elevator is out of order.",  
    "The parking lot is always full.",  
    "The chairs in the waiting area are uncomfortable.",  
    "The lighting in the hallways is too dim.",  
    "Some other complaint not related to specific facilities.",  
    "Another generic complaint.",  
]
```

De seguida temos as reclamações de treino serão utilizadas para treinar o modelo.

```

training_categories = [
    "facility_related",
    "facility_related",
    "facility_related",
    "facility_related",
    "facility_related",
    "facility_related",
    "other",
    "other",
]

```

E, por fim, temos as categorias que correspondem a cada frase de treino utilizadas acima.

```

model = make_pipeline(CountVectorizer(), MultinomialNB())

```

Neste código está representado o modelo utilizado na aplicação em que são utilizados dois métodos do sklearn que são o Count Vectorizer que simplesmente transforma cada palavra numa frase dada em um token e conta as vezes que o mesmo token aparece e o método MultinomialNB utiliza o teorema de Naive Bayes e a informação dada pelo Count Vectorizer para atribuir uma categoria.

```

@app.route('/complaints', methods=['GET'])
def get_complaints():
    complaints_data = list(collection.find({}, {'_id': 0})) # Retrieve
all complaints data
    return jsonify(complaints_data), 200

```

A api criada pelo flask tem apenas um método para obter todos os complaints que foram analisados e guardados na base de dados e será utilizada pela aplicação mobile para esta receber a informação.

```
with open('test_complaints.txt', 'r') as file:
    test_complaints = file.read().splitlines()
```

Esta função lê o ficheiro em que estão as frases que vão ser testadas e trata da divisão das frases por linhas.

```
for idx, complaint in enumerate(test_complaints, 1):
    category = predict_category(complaint)
    print(f"Complaint {idx}: {complaint}\nCategory: {category}\n")
    store_in_mongodb(complaint, category)
```

```
def predict_category(complaint):
    predicted_category = model.predict([complaint])
    return predicted_category[0]
```

```
def store_in_mongodb(complaint, category):
    complaint_data = {
        "complaint": complaint,
        "category": category
    }
    collection.insert_one(complaint_data)
```

Aqui é utilizado um *for* que itera por todas as frases e em cada uma delas atribui uma categoria utilizando a função `predict_category` e, de seguida armazena na base de dados com a função `store_in_mongodb`.

4.2. Mobile App

A mobile app foi utilizada apenas para mostrar informação que é recebida através da flask API do backend e mostrada através de uma lista.

SimilarityApp
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste Categoria: Teste
Reclamação: Teste

Figura 1 – Mockup da Mobile App

4.3. Testes e Resultados

Para vermos a eficácia do modelo apresentado foram realizados vários testes variando a quantidade de frases de treino:

4.3.1. Primeiro teste

Para o primeiro teste irá ser utilizada apenas uma frase de treino de cada categoria e será testada em três frases de cada categoria:

4.3.1.1. Categoria - Facility Related

Complaint 1: The restroom facilities are outdated and in need of modernization.

Category: product_related

Complaint 2: The hand sanitizer dispensers are frequently empty, posing a hygiene concern in the facility.

Category: facility_related

Complaint 3: There is a persistent leak in the ceiling near the entrance, creating a safety hazard.

Category: facility_related

As primeiras três reclamações deveriam ser facility related, mas como há apenas uma frase para teste em cada uma das categorias o modelo de treino não tem informação suficiente para responder corretamente a categoria.

4.3.1.2. Categoria - Product Related

Complaint 4: The latest product release has a significant decrease in quality compared to previous versions.

Category: product_related

Complaint 5: The packaging of the product is flimsy, leading to damage during shipping.

Category: facility_related

Complaint 6: The user interface of the application is confusing, making it difficult for customers to navigate.

Category: facility_related

No caso das reclamações 4,5 e 6 que deveriam ser todas as frases pertencentes à categoria product related também houve uma diferença na categoria atribuída pelo modelo devido também à falta de frases de treino.

4.3.1.3. Categoria - Other

Complaint 7: The company's promotional emails are too frequent and annoying.

Category: product_related

Complaint 8: The website frequently experiences downtime, affecting online services.

Category: other

Complaint 9: The company's billing system is confusing, leading to overcharges for some customers.

Category: facility_related

Nas 3 últimas reclamações apenas a reclamação 8 obteve a categoria correta e mais uma vez pelo baixo número de frases no modelo de treino.

4.3.2. Segundo Teste

No segundo teste adicionei mais 4 frases de treino a cada categoria e testei nas mesmas frases de teste para ver se os resultados variavam:

4.3.2.1. Categoria – Facility Related

Complaint 1: The restroom facilities are outdated and in need of modernization.

Category: facility_related

Complaint 2: The hand sanitizer dispensers are frequently empty, posing a hygiene concern in the facility.

Category: facility_related

Complaint 3: There is a persistent leak in the ceiling near the entrance, creating a safety hazard.

Category: facility_related

Após a adição de mais frases de treino as categorias das reclamações corresponderam ao esperado e a informação devolvida foi a correta, o que já era esperado devido a uma maior amostra de frases a serem analisadas para treino.

4.3.2.2. Categoria – Product Related

Complaint 4: The latest product release has a significant decrease in quality compared to previous versions.

Category: product_related

Complaint 5: The packaging of the product is flimsy, leading to damage during shipping.

Category: product_related

Complaint 6: The user interface of the application is confusing, making it difficult for customers to navigate.

Category: other

Para a categoria product related apenas uma das frases estava errada significando que o algoritmo melhorou, mas seria necessária uma maior amostra para que fosse 100% eficaz.

4.3.2.3. Categoria - Other

Complaint 7: The company's promotional emails are too frequent and annoying.

Category: other

Complaint 8: The website frequently experiences downtime, affecting online services.

Category: other

Complaint 9: The company's billing system is confusing, leading to overcharges for some customers.

Category: product_related

Como na categoria anterior o algoritmo falhou apenas em uma das frases testadas sendo mais eficaz que o primeiro teste, mas ainda não prevê todas as categorias de forma acertada.

4.4. Conclusão

Depois da realização dos testes podemos concluir que o algoritmo poderá ser utilizado numa situação real pressupondo que o nível de amostras que são dadas ao modelo de testes for grande e, assim, garantir que irá atribuir de forma correta a categoria de cada reclamação que é recebida de cada utilizador dos serviços da empresa em questão.

A necessidade de uma grande amostra pode ser uma desvantagem para uma empresa que quer começar a utilizar o algoritmo e não tem dados que alimentem o treino do modelo e, por isso teriam que receber algumas reclamações, atribuir uma categoria manualmente e só depois era possível automatizar este sistema.

5. Bibliografia

Knuth, D. (1973). *The Art of Computer Programming*. Adison Wesley.

Majid M., S. N. (2022). *Computing semantic similarity of texts based on deep graph learning with ability to use semantic role label information*.

Mingyu J., X. Z. (2022). *A Short Text Similarity Calculation Method Combining Semantic and Headword Attention Mechanism*.

Mohammadi, H. &. (2020). A fast text similarity measure for large document collections using multireference cosine and genetic algorithm. 28(2), pp. 999-1013.

PennState University Libraries. (15 de Março de 2017). *APA Quick Citation Guide*. Obtido de PennState University Libraries Web Site: <http://guides.libraries.psu.edu/apaquickguide/intext>

Weidong Z., X. L. (2022). *Re-LSTM: A long short-term memory network text similarity algorithm based on weighted word embedding*.